

RELATÓRIO TÉCNICO DE ENTREGA

Mercado de combustíveis no Brasil

Pipeline de dados para volume declarado, concentração e preços de revenda por UF — 2022 a 2024

Autora: Fabiola Dias Carvalho

Projeto: MVP PUC | **Ambiente:** Databricks | **Lote:** anp_br_20260909T081743Z_9b2d128e

42	26	16
tabelas publicadas	regras de qualidade	capturas da execução nacional

Propósito. Construir uma trilha reproduzível desde os arquivos públicos da ANP até análises por UF, sem confundir vendedor, bandeira, preço de posto e volume municipal.

Versão revisada para leitura em papel. As conclusões usam apenas resultados do lote executado; as limitações aparecem junto das evidências.

1. Objetivo, recorte e perguntas

O objetivo foi integrar dados públicos da ANP para descrever o volume de gasolina C e etanol hidratado declarado por vendedor em cada UF, a concentração associada a esse volume e o contexto de preços de revenda e vendas municipais. A unidade principal é **UF x mês x produto x vendedor**.

Nº	Como foi respondida
1	Ranking mensal por vendedor, UF e produto; consolidação anual apenas como apoio.
2	Participação da líder, Top 3 e HHI por UF, mês e produto.
3	Volume e participação de Vibra, Ipiranga, Raízen e ALE onde aparecem.
4	Preço mediano, dispersão e intensidade de coleta por UF.
5	Associação descritiva entre preço, concentração e volume por UF-mês.
6	Reconciliação anual entre Logística 02 e vendas municipais.
7	Fotografia atual de bandeiras, sem reconstituir rede histórica.

Decisões de escopo

- Período observado: janeiro de 2022 a dezembro de 2024; produtos principais: gasolina C e etanol hidratado.
- Vendedor é quem declara volume na Logística 02. Não é usado como sinônimo de marca de posto ou bandeira.
- Preço é pesquisa amostral; volume municipal é anual. Cruzamentos preservam a granularidade de cada fonte.

Regra de leitura. Correlação e concentração descrevem padrões observados. Não são usadas para afirmar causa e efeito.

A matriz completa de pergunta, tabela, consulta, captura e limite está em **docs/matriz_respostas.md**.

2. Fontes, coleta e rastreabilidade

Foram mantidas separadas as quatro fontes públicas porque elas não descrevem o mesmo fenômeno e não possuem a mesma chave de negócio.

Fonte	Granularidade	Uso
Logística 02	vendedor × UF × produto × mês	volume declarado, participação e concentração
Preços ANP	posto × produto × data	mediana, dispersão, postos e coletas
Vendas municipais	município × produto × ano	escala e reconciliação anual
Cadastro	revendedor × data de extração	contexto atual da rede

225.398	2.710.038	141.622
linhas Logística 02 na Bronze	observações de preços na Bronze	vendas por vendedor tipadas




Figura 1 — Lote Bronze, fontes e contagens registradas no Databricks. A tabela mantém o identificador de carga e a data de ingestão.

Os arquivos brutos não entram no repositório. URLs, datas de acesso e hashes SHA-256 estão resumidos em docs/registro_coleta.md.

3. Arquitetura, modelo e linhagem

O pipeline preserva a origem na Bronze, aplica tipagem e flags na Silver e disponibiliza dimensões, fatos, regras de qualidade e marts analíticos na Gold.



ANP → Volume do Databricks → tabelas Delta e consultas reproduzíveis

Modelo analítico

Componente	Granularidade / finalidade
Dimensões	tempo, UF, município, produto, empresa, revenda, bandeira e lote
Fato de venda	vendedor × UF × produto × mês, com volume líquido e grupo econômico
Fato de preço	UF × produto × mês, com mediana, percentis, postos e coletas
Mart estadual	UF × produto × mês, integrando volume, concentração e preço
Reconciliação	UF × ano × grupo de produto, com diferença e status

Transformações relevantes

- Datas e números são tipados; quantidade negativa é mantida e marcada como ajuste.
- Produtos e grupos econômicos usam CSVs versionados. Município é conciliado ao código IBGE antes do mart municipal.
- Preço e volume só se encontram depois de agregação compatível por UF, mês e produto.

4. Qualidade e catálogo de dados

A qualidade é registrada como resultado do lote, e não como limpeza silenciosa. O catálogo observado traz tipo, nulos, distintos, mínimos e máximos; os domínios e a linhagem são descritos no CSV versionado.

19	7	0
regras aprovadas	regras informativas	regras em atenção




Figura 2 — Regras executadas na Gold com quantidade afetada, percentual e status visíveis.

Evento observado	Tratamento adotado
941 linhas sem UF válida	preservadas na Silver; fora dos agregados estaduais
337 ajustes negativos	marcados como ajuste; não removidos para melhorar totais
28 chaves repetidas de preço	desempate determinístico nas agregações; dado permanece auditável
43.790 outliers IQR	sinalizados; não apagados da origem

As entradas ampliadas no arquivo de configuração de catálogo entram no próximo processamento do notebook 03; a documentação distingue essa configuração do perfil já registrado pelo lote de 9 de setembro.

5. Ranking de vendedores: resposta no nível mensal

A primeira pergunta do projeto pede UF, mês e produto. A consulta principal, portanto, calcula participação e posição nessa granularidade. A consolidação anual é usada apenas para facilitar a leitura de um período completo.




Figura 3 — Ranking mensal de etanol hidratado no DF, dezembro de 2023. Período, posição, empresa, volume e participação estão visíveis.

Posição	Empresa	Volume (milhões L)	Participação
1	Ipiranga	5,817	30,213%
2	Vibra Energia	4,970	25,814%
3	Raízen	4,605	23,919%

No resumo anual de 2023, as mesmas três empresas lideram o etanol do DF. O grupo econômico é uma classificação adicional e não elimina empresas fora do mapeamento.

6. Concentração: HHI, Top 3 e participação da líder

A série mensal está na Gold. Para comparação anual, o HHI foi recalculado diretamente a partir do volume anual por empresa, evitando a média de indicadores mensais.




Figura 4 — Dois contrastes no etanol de 2022: Amapá e Minas Gerais. A tela mostra número de vendedores, HHI, Top 3, participação da líder e faixa.

UF	Vendedores	HHI	Top 3	Líder
AP	4	9.235	99,06%	96,07%
MG	83	1.248	58,04%	21,42%

O contraste mostra estruturas distintas no volume declarado. Ele não atribui a concentração a preço, bandeira ou desempenho de postos específicos.

7. Preço, dispersão e intensidade de coleta

Preço é resumido como mediana das medianas mensais por UF. O spread médio P90–P10 é uma medida de dispersão da amostra; a quantidade de coletas descreve sua intensidade, não o tamanho do mercado.




Figura 5 — Extremos de preço mediano, dispersão e coletas para etanol hidratado em 2024.

Indicador	Maior	Menor
Mediana de preço	RO — R\$ 4,990	MT — R\$ 3,590
Spread médio P90–P10	PA — R\$ 1,043	RR — R\$ 0,100
Coletas anuais	SP — 62.850	AP — 112

Todas as comparações de preço permanecem acompanhadas de meses, postos e coletas na consulta de apoio. A ausência de coleta não é interpretada como ausência de mercado.

8. Relação descritiva entre volume, concentração e preço

O mart estadual une medidas agregadas por UF, mês e produto. A correlação é calculada somente quando preço e volume estão disponíveis; cada produto-ano teve 324 observações UF-mês no lote.





Figura 6 — Coeficientes de correlação por ano e produto, executados no Databricks.

Ano / produto	log(volume) × preço	HHI × preço	Top 3 × preço
2022 — etanol	−0,3485	0,3474	0,3659
2023 — etanol	−0,7589	0,6166	0,5950
2024 — etanol	−0,6690	0,4964	0,4971
2024 — gasolina C	−0,3593	0,1937	0,2148

O resultado é descritivo: não demonstra que volume, concentração ou preço causou qualquer uma das outras variáveis.

9. Volumes anuais e cobertura municipal

A fonte logística e as vendas municipais não são substituídas uma pela outra. A reconciliação mede a diferença de escopo, mantendo os meses logísticos observados e um status explícito.



Etanol em 2022: os dois volumes, a diferença percentual e o status aparecem na mesma tela.

Cobertura da pesquisa de preços nos municípios com venda publicada.

Figura 7 — Evidências capturadas no Databricks durante a revisão final.

Caso	Resultado
MG, etanol, 2022	12 meses; -1,864%; DIVERGÊNCIA DE ESCOPO
MT, etanol, 2022	12 meses; 0,133%; COMPATÍVEL
Cobertura municipal 2024	etanol: 10,04%; gasolina C: 8,34%

A cobertura parcial é uma limitação de publicação e comparação, não uma justificativa para excluir linhas da origem.

10. Cadastro de revendedores: contexto, não história

O cadastro é uma fotografia do momento de extração. Ele foi utilizado para descrever a composição atual de bandeiras e apoiar auditorias, sem transportar a situação atual para os anos de 2022 a 2024.




Figura 8 — Fotografia da rede por bandeira no Amazonas, na data de extração registrada pelo lote.

Bandeira	Revendas	Participação na fotografia
Bandeira Branca	302	35,20%
ATEM'S	245	28,55%
Equador	126	14,69%
Vibra	62	7,23%
Ipiranga	50	5,83%

Bandeira e vendedor pertencem a universos diferentes. A análise não cria uma ligação direta entre uma empresa da Logística 02 e um posto pesquisado.

11. Verificação do enunciado e autoavaliação

A revisão final foi organizada para que cada item avaliado tenha código, documentação e evidência correspondente. A apresentação HTML e este relatório usam o mesmo conjunto de fatos e capturas.

Exigência	Material entregue
Objetivo e perguntas	docs/objetivo.md e docs/matriz_respostas.md
Fontes e termos	docs/fontes_e_linhagem.md e docs/registro_coleta.md
Persistência em nuvem	Volume, Bronze, lote, manifestos e captura 02
Modelo e catálogo	docs/modelo_dados.md, configuração e captura 05
Transformação e qualidade	notebooks 00-03, captura 04 e captura 06
Resposta às perguntas	notebooks 04-05, capturas 07-16 e discussão
Fechamento	docs/autoavaliacao.md, apresentação HTML e PDF

Dificuldade central

As fontes públicas não foram criadas para responder a uma única pergunta. A solução foi preservar as granularidades, publicar a reconciliação e tratar cobertura, diferenças de escopo e fotografia cadastral como limites do resultado.

Próximos passos

- Atualizar a coleta e comparar versões de arquivos e mapeamentos.
- Ampliar a classificação auditável de empresas, com vigência e fonte da regra.
- Criar testes de contrato para mudanças de colunas, tipos e domínios antes da Bronze.

12. Reprodução e referências

O projeto pode ser reproduzido pela sequência de notebooks e pelas consultas SQL documentadas. Dados brutos, manifestos locais detalhados e credenciais permanecem fora do GitHub.

Roteiro de reprodução

Etapa	Arquivo
Coletar e inspecionar	scripts/download_anp.py e scripts/inspect_raw.py
Preparar e carregar	notebooks/00_preparar_arquivos_anp.py e 01_ingestao_bronze.py
Transformar e qualificar	notebooks/02_transformacao_modelo.py e 03_qualidade_dados.py
Analisar e capturar	notebooks/04_analises.sql e 05_capturas_evidencias.sql
Conferir resultados	docs/discussao_resultados.md, evidencias.md e autoavaliacao.md

Referências oficiais

- ANP. Central de Dados Abertos: gov.br/anp/pt-br/centrais-de-conteudo/dados-abertos/dados-abertos.
- ANP. Série Histórica de Preços de Combustíveis: gov.br/anp/pt-br/centrais-de-conteudo/dados-abertos/serie-historica-de-precos-de-combustiveis.
- ANP. Logística 02, vendas municipais e cadastro de revendedores: URLs e hashes em docs/registro_coleta.md.

Repositório público

github.com/niciusr/projeto-puc-fabiola-mercado-combustiveis-rj

Fechamento. O resultado não é apenas um ranking: é uma trilha verificável da fonte ao resultado, com escolhas de integração e limites metodológicos expostos.